

# 图像处理与计算机视觉研讨课： 第一次作业

姓名： 张宗樽

学号： 2023K8009991013

2025 年 12 月 3 日

# 目录

<b>1 环境配置 (Environment Setup)</b>	<b>2</b>
1.1 SAM 模型配置 . . . . .	2
1.2 DeepLab v3+ 模型使用 . . . . .	2
1.3 归一化图割 . . . . .	3
<b>2 实验结果展示 (Results)</b>	<b>4</b>
2.1 公开数据集测试结果 . . . . .	4
2.2 自采数据集测试结果 . . . . .	6
<b>3 同类分析</b>	<b>8</b>
3.1 SAM模型 . . . . .	8
3.1.1 权重文件对比: ViT-B 与 ViT-H . . . . .	8
3.1.2 实验结果与分析 . . . . .	9
3.1.3 结论 . . . . .	11
3.2 DeepLabV3+ 模型 . . . . .	11
3.2.1 权重文件对比: Pascal VOC 与 Cityscapes . . . . .	11
3.2.2 实验结果与分析 . . . . .	12
3.2.3 结论 . . . . .	13
<b>4 不同模型对比分析</b>	<b>14</b>
4.1 Normalized Cut (N-Cut) 算法 . . . . .	14
4.1.1 算法原理 . . . . .	14
4.1.2 优化与求解 . . . . .	14
4.2 实验结果分析 . . . . .	15
4.2.1 场景一: 复杂重叠物体 (瓶中花) . . . . .	15
4.2.2 场景二: 低照度与低对比度 (暗光猫) . . . . .	16
4.2.3 场景三: 自然场景 . . . . .	16

# 1 环境配置 (Environment Setup)

## 1.1 SAM 模型配置

SAM 的配置主要包括安装官方库以及下载不同规模的预训练权重（ViT-B 和 ViT-H）。

Listing 1: SAM 环境安装与权重下载

```
1 # 1. 安装 segment-anything 库
2 pip install git+https://github.com/facebookresearch/segment-anything.git
3
4 # 2. 下载预训练权重文件
5 wget https://dl.fbaipublicfiles.com/segment_anything/sam_vit_h_4b8939.pth
6 wget https://dl.fbaipublicfiles.com/segment_anything/sam_vit_b_01ec64.pth
```

Listing 2: SAM 模型加载代码示例

```
1 from segment_anything import sam_model_registry, SamPredictor
2
3 sam_checkpoint_h = "sam_vit_h_4b8939.pth"
4 model_type_h = "vit_h"
5 sam_h = sam_model_registry[model_type_h](checkpoint=sam_checkpoint_h)
6
7 sam_checkpoint_b = "sam_vit_b_01ec64.pth"
8 model_type_b = "vit_b"
9 sam_b = sam_model_registry[model_type_b](checkpoint=sam_checkpoint_b)
```

## 1.2 DeepLab v3+ 模型使用

下载DeepLab v3+ 在 Cityscapes 和 Pascal VOC 数据集上的预训练权重，并使用以下命令进行测试。

Listing 3: DeepLab v3+ 模型测试脚本

```
1 # 使用 cityscapes
2 python predict.py --input dataset/4.jpg \
3     --dataset cityscapes \
4     --model deeplabv3plus_mobilenet \
5     --ckpt checkpoints/best_deeplabv3plus_mobilenet_cityscapes_os16.pth \
6     --save_val_results_to cityscapes_result
7
8 # 使用 pascal voc
9 python predict.py --input dataset/5.jpg \
10    --dataset voc \
11    --model deeplabv3plus_mobilenet \
12    --ckpt checkpoints/best_deeplabv3plus_mobilenet_voc_os16.pth \
13    --save_val_results_to voc_results
```

### 1.3 归一化图割

具体实现基于 `scikit-image` 库。

Listing 4: 基于 SLIC 超像素的归一化图割实现代码

```
1 from skimage import segmentation, color, graph
2 import cv2
3 import os
4
5 profile_dir = './dataset'
6 os.makedirs("./Ncutresults", exist_ok=True)
7
8 for file in os.listdir(profile_dir):
9     image = cv2.imread(os.path.join(profile_dir, file))
10    img = cv2.cvtColor(image, cv2.COLOR_BGR2RGB)
11    labels1 = segmentation.slic(img, compactness=30, n_segments=200, start_label=1)
12    g = graph.rag_mean_color(img, labels1, mode='similarity')
13    labels2 = graph.cut_normalized(labels1, g)
14    out2 = color.label2rgb(labels2, img, kind='avg', bg_label=0)
15    out2_bgr = cv2.cvtColor((out2 * 255).astype('uint8'), cv2.COLOR_RGB2BGR)
16    cv2.imwrite(os.path.join("./Ncutresults", f"ncut_{file}"), out2_bgr)
```

## 2 实验结果展示 (Results)

本章节展示归一化图割、DeepLab v3+ 以及 SAM 在公开数据集和自采数据集上的分割效果。

### 2.1 公开数据集测试结果







图 1: 公开数据集测试用例 1




(a) 原图 (Original)




(b) Normalized Cuts




(c) DeepLab (Cityscapes)



(d) DeepLab (Pascal VOC)




(e) SAM (ViT-B)




(f) SAM (ViT-H)


图 2: 公开数据集测试用例 2




(a) 原图 (Original)




(b) Normalized Cuts




(c) DeepLab (Cityscapes)



(d) DeepLab (Pascal VOC)




(e) SAM (ViT-B)




(f) SAM (ViT-H)


图 3: 公开数据集测试用例 3




(a) 原图 (Original)




(b) Normalized Cuts




(c) DeepLab (Cityscapes)



(d) DeepLab (Pascal VOC)



(e) SAM (ViT-B)




(f) SAM (ViT-H)

图 4: 公开数据集测试用例 4


## 2.2 自采数据集测试结果



(a) 原图 (Original)




(b) Normalized Cuts




(c) DeepLab (Cityscapes)




(a) 原图 (Original)




(b) Normalized Cuts




(c) DeepLab (Cityscapes)



(d) DeepLab (Pascal VOC)




(e) SAM (ViT-B)




(f) SAM (ViT-H)


图 6: 自采数据集测试用例 2




(a) 原图 (Original)




(b) Normalized Cuts




(c) DeepLab (Cityscapes)



(d) DeepLab (Pascal VOC)



(e) SAM (ViT-B)



(f) SAM (ViT-H)

图 7: 自采数据集测试用例 3




图 8: 自采数据集测试用例 4

### 3 同类分析

在这一部分，我们将对比DeepLab v3+ 与 SAM 在采用不同预训练模型时的表现。

#### 3.1 SAM模型

SAM 是 Meta AI 提出的 Segment Anything Model (SAM) 作为图像分割的基础框架。SAM 旨在解决通用的图像分割任务，具有强大的零样本迁移能力，能够处理训练集中未见过的物体类别。

SAM 的网络架构由三个主要部分组成，设计上实现了高效的推理：

- **图像编码器 (Image Encoder):** 基于 Vision Transformer (ViT) 架构，负责将输入图像映射为特征嵌入 (Image Embeddings)。这是模型中计算量最大的部分，但对每张图像仅需计算一次。
- **提示编码器 (Prompt Encoder):** 这是一个轻量级模块，用于将用户的交互提示（如点、框、掩码或文本）转换为提示向量。
- **掩码解码器 (Mask Decoder):** 该模块将图像特征与提示特征相结合，通过轻量级的计算实时生成最终的分割掩码。


##### 3.1.1 权重文件对比：ViT-B 与 ViT-H

SAM 的不同模型版本主要区别在于图像编码器的大小。本研究使用了官方提供的两个具有代表性的权重文件进行对比实验：**ViT-B (Base)** 和 **ViT-H (Huge)**。


- **ViT-B (Base):** 这是一个基础版本的模型权重。它的参数量相对较小，推理速度快，内存占用低。在资源受限或对实时性要求较高的场景中，ViT-B 通常是首选。
- **ViT-H (Huge):** 这是 SAM 系列中规模最大、性能最强的版本。它拥有巨大的参数量，能够提取更丰富的图像特征。虽然其计算成本显著增加，但在处理复杂场景、模糊边界以及细小物体时，ViT-H 通常能提供更精细的分割质量。

### 3.1.2 实验结果与分析

为了评估模型容量对分割性能的具体影响，我们在室内复杂背景、多人物实例以及自然景观三种典型场景下，对比了 ViT-B (Base) 与 ViT-H (Huge) 两个不同量级权重的表现。实验采取仅显示最大的5个掩码作为输出。



(a) ViT-B 分割结果




(b) ViT-H 分割结果

图 9: 室内场景对比

**前景主体与背景识别** 如图 9 所示，两者表现差异巨大。**ViT-B** (图a) 显然受到了背景中高对比度图案的干扰，其“Top 5”分割结果主要集中在画面两侧的彩色条纹（紫色、绿色、红色块），而作为画面的真正主体——猫，却几乎融入背景。相比之下，**ViT-H** (图b) 展现了较好的语义聚焦能力，它成功抑制了背景噪声的干扰，将画面中央的猫识别为最显著的单一对象（亮紫色区域），且轮廓完整清晰。



SAMresults-vit\_b/sam\_5.png




SAMresults-vit\_h/sam5.png

(a) ViT-B 分割结果

(b) ViT-H 分割结果

图 10: 人物实例分割对比

**人物实例** 对比图 10 可以看出，**ViT-B** 在语义理解上存在碎片化问题。它未能理解肢体与躯干的从属关系，错误地将左侧球员举起的手臂丢失，并将右侧球员分割为上下两部分。而 **ViT-H** 表现出极强的语义连通性，准确地将头部、躯干和四肢识别为同一个实例，证明了其具备更深层的语义理解能力，而非简单的颜色聚类。



(a) ViT-B 分割结果

(b) ViT-H 分割结果

图 11: 自然景观分割对比

**自然景观** 如图 11 所示, **ViT-B** 生成的掩码显得杂乱且缺乏明确语义, 仅覆盖了草坪的局部碎片。相反, **ViT-H** 能够结合全局上下文信息, 生成了覆盖整块左侧草坪的完整掩码, 且掩码边缘沿着硬质路面切分得非常整齐。这说明 ViT-H 在处理低纹理区域时具有更好的鲁棒性和区域一致性。

### 3.1.3 结论

综合上述实验, 从 ViT-B 升级至 ViT-H 带来了显著的性能提升。具体表现在:

1. **抗干扰能力:** ViT-H 能有效区分前景主体与背景高频噪声 (如实验一中的猫与背景条纹)。
2. **语义完整性:** ViT-H 能更好地理解物体的结构, 避免将同一物体分割破碎 (如实验二中的人物)。
3. **区域一致性:** 在低纹理区域, ViT-H 能生成更符合人类认知的完整掩码 (如实验三中的草地)。

## 3.2 DeepLabV3+ 模型

DeepLabV3+ 是由 Google 团队提出的经典语义分割网络。

DeepLabV3+ 的核心架构包含两个关键特性:

- **空洞空间金字塔池化:** 通过不同采样率的空洞卷积捕捉多尺度的上下文信息, 显著提升了模型对不同大小物体的识别能力。
- **编解码器结构:** 引入了简单的解码器模块。编码器提取丰富的高层语义特征, 而解码器通过上采样并将低层细节特征与高层语义特征融合, 有效地恢复了物体的空间分辨率和边界细节。

这种设计使得 DeepLabV3+ 在保持较高分割精度的同时, 能够生成边缘更加锐利的分割结果。

### 3.2.1 权重文件对比: Pascal VOC 与 Cityscapes

本实验对比了分别在 Pascal VOC 和 Cityscapes 数据集上训练的两个权重文件, 它们决定了模型能够识别的语义类别。

- **Pascal VOC 权重**: 该权重在 PASCAL VOC 2012 数据集上训练。它侧重于通用物体分割，包含 20 个前景类别（如人、猫、狗、椅子、飞机、汽车等）和 1 个背景类。该模型适合处理生活中常见的独立物体，注重物体层面的实例区分。
- **Cityscapes 权重**: 该权重在 Cityscapes 数据集上训练。它专注于城市自动驾驶场景，包含 19 个语义类别（如道路、人行道、建筑、墙、交通标志、车辆、行人等）。该模型不仅关注前景物体，还关注背景环境（如天空、地面）的语义解析，适合处理复杂的街景图像。

### 3.2.2 实验结果与分析

不同于 SAM 模型中模型容量带来的差异，DeepLabV3+ 的对比实验主要揭示了预训练数据集（Pascal VOC 与 Cityscapes）对模型语义认知范围的影响。





图 12: 街景分割对比

**城市街景场景解析** 如图 12 所示，两者差异显著。**Pascal VOC 权重** (图a) 表现为稀疏的物体检测，仅将画面中的车辆识别为前景（灰色区域），而将道路、树木和天空均视为背景（黑色）。这是因为 VOC 数据集主要针对特定物体类别的实例分割。相反，**Cityscapes 权重** (图b) 展现了密集的语义分割能力，正确将像素分类为道路（紫色）、植被（绿色）、天空（蓝色）和车辆（深蓝色），提供了完整的环境语义信息。




(a) Pascal VOC 权重结果




(b) Cityscapes 权重结果

图 13: 通用物体识别对比

**室内物体泛化能力** 图 13 展示了严重的领域偏移现象。Pascal VOC 权重 (图a) 准确地将花卉识别为“盆栽/植物”类别 (绿色掩码)，覆盖完整。然而，Cityscapes 权重 (图b) 产生了严重的“幻觉”，将花卉错误地强制分类为各种杂乱的街景类别碎片。



(a) Pascal VOC 权重结果



(b) Cityscapes 权重结果

图 14: 环境背景分割

**自然景观** 在图 14 中，Pascal VOC 权重 (图a) 几乎输出全黑结果，因为它不包含“草地”、“路面”或“天空”等背景类别，只能忽略。而 Cityscapes 权重 (图b) 凭借对室外场景的先验知识，清晰地分割出了草地 (亮绿色)、远山与树木 (深绿色)，以及天空 (蓝色)。

### 3.2.3 结论

对于 DeepLabV3+ 而言，权重的选择应严格取决于应用场景：

1. 若任务涉及通用物体检测（如机器人抓取、相册分类），应选择涵盖 20 类常见物体的 **Pascal VOC** 权重。
  2. 若任务涉及自动驾驶或环境感知，需要理解道路布局和背景，则必须使用 **Cityscapes** 权重。
- 模型无法识别其训练数据分布之外的语义类别，盲目跨域使用会导致严重的漏检或误识别。

## 4 不同模型对比分析

本章节将归纳总结归一化图割、DeepLab v3+ 以及 SAM 三种图像分割方法在不同应用场景下的优缺点。

### 4.1 Normalized Cut (N-Cut) 算法

#### 4.1.1 算法原理

N-Cut 算法将图像分割问题建模为图的划分问题。给定一幅图像，将其表示为加权无向图  $G = (V, E)$ ，其中  $V$  代表图像中的像素集合， $E$  代表连接像素的边。每条边的权重  $w_{ij}$  反映了节点  $i$  与节点  $j$  之间的相似度（通常基于颜色相似性和空间距离计算）。

传统的最小割（Min-Cut）算法旨在找到一种划分方式，使得被切断的边的权重之和最小。然而，Min-Cut 倾向于分割出孤立的节点。为了解决这一偏置，N-Cut 引入了归一化项，将分割成本与子图的总体积相关联。其目标函数定义为：

$$Ncut(A, B) = \frac{cut(A, B)}{assoc(A, V)} + \frac{cut(A, B)}{assoc(B, V)} \quad (1)$$

其中：

- $A$  和  $B$  是图  $V$  被分割成的两个互不相交的子集（即  $A \cup B = V, A \cap B = \emptyset$ ）。
- $cut(A, B) = \sum_{i \in A, j \in B} w_{ij}$  是两个子集之间被切断的边的权重总和。
- $assoc(A, V) = \sum_{i \in A, t \in V} w_{it}$  是子集  $A$  中所有节点与图中所有节点的连接权重总和（即子集  $A$  的总体积）。

#### 4.1.2 优化与求解

最小化  $Ncut(A, B)$  是一个 NP-hard 问题。然而，Shi 和 Malik 证明了该问题可以转化为广义特征值问题（Generalized Eigenvalue Problem）进行近似求解。通过求解拉普拉斯矩阵的特征向量，并将像素映射到特征空间进行聚类，即可得到最优的分割结果。与现代深度学习方法不同，N-Cut 是一种非监督学习方法，不需要任何训练数据，但其计算复杂度随图像分辨率呈平方级增长，因此在处理高分辨率图像时效率较低。

## 4.2 实验结果分析

### 4.2.1 场景一：复杂重叠物体（瓶中花）




图 15: 瓶中花场景下的模型结果对比

#### 1. Ncut (归一化图割) 分析:

在该场景中，Ncut 表现出典型的过分割 (**Over-segmentation**) 现象。观察图 (a)，算法深受花瓣内部颜色渐变（深红至浅粉）的影响，将完整的花朵切碎成多个不规则的色块。同时，由于缺乏对物体形状的先验认知，紫色花瓶与上方绿叶的边界处理混乱，无法形成独立的物体区域。

#### 2. Semantic (DeepLabV3+) 分析:

DeepLabV3+ 成功提取了图像的高层语义，将画面中的花束和花瓶整体识别为 PASCAL VOC 类别中的 *pottedplant* (图 (b) 绿色区域)。然而，其局限性在于丢失了实例细节。由于骨干网的下采样操作，不同花朵之间的界限被模糊，整个花束呈现为一个粗糙的连通区域 (Blob)，无法区分个体，且边缘细节平滑严重。

#### 3. SAM (Segment Anything) 分析:

SAM 在此场景下展现了卓越的实例分割 (**Instance Segmentation**) 能力。观察结果 (c)，模型不仅成功将前景与背景分离，更在严重的物体遮挡下，精准地扣取了特定的紫色玫瑰花（紫色 Mask）和花瓶（棕色 Mask）。其边缘贴合度极高，连花瓣的锯齿状边缘都清晰可见，证明了 ViT 架构在处理复杂重叠边缘时的强大感知力。

#### 4.2.2 场景二：低照度与低对比度（暗光猫）




图 16: 低照度场景下的模型结果对比

##### 1. Ncut (归一化图割) 分析:

在低光照且对比度极低的条件下，Ncut 几近失效。由于猫的毛色与背景木地板及阴影极其接近，基于颜色和梯度的聚类无法形成有效的边界。如图 (a) 所示，算法反而被背景中纹理更明显的椅子腿误导（右侧深蓝色块），将背景切碎，而未能提取出主体目标。

##### 2. Semantic (DeepLabV3+) 分析:

DeepLabV3+ 展现了深度学习方法的语义鲁棒性。尽管视觉边界模糊，CNN 依然通过猫的耳朵、眼睛等特征，在语义层面成功识别出了 Cat 类（图 (b) 红色区域）。但是，其分割掩码的边缘非常圆滑，丢失了猫爪、耳尖等形态细节，表现为一种“定位准确但轮廓模糊”的结果。

##### 3. SAM (Segment Anything) 分析:

SAM 的表现最为惊艳。得益于 Transformer 的全局注意力机制 (Global Attention)，模型利用整张图的上下文信息弥补了局部对比度的不足。结果 (c) 显示，SAM 生成的掩码轮廓完美贴合了猫的身体，保留了尖锐的耳尖和独立的尾巴线条。这证明了基础大模型 (Foundation Model) 在理解物体形态上已经超越了单纯的颜色或梯度依赖。

#### 4.2.3 场景三：自然场景




图 17: 自然场景对比

##### 1. Ncut (归一化图割) 分析:

在自然场景下，Ncut 表现出明显的区域块状化特征。如图 (a) 所示，算法大致将灰色的路面（灰色

块) 与两侧的草地 (紫色块) 进行了分离。然而, 对于路面上的小物体 (猫和路桩), Ncut 仅仅将其处理为边缘锯齿严重、形状难以辨认的色块 (蓝色/棕色斑点), 无法准确描绘物体的真实轮廓。这表明 Ncut 适合处理颜色差异明显的宏观区域, 但不具备精细物体的捕捉能力。

## 2. Semantic (DeepLabV3+) 分析:

DeepLabV3+ 在处理 **远景小目标 (Small Objects)** 时表现出明显劣势。结果 (b) 中充满了噪声, 虽然大致定位了猫的方位 (红色斑点), 但未能形成清晰的物体轮廓。这是由于深层网络多次下采样后, 小目标的特征信息严重衰减, 导致上采样恢复时分辨率不足, 且背景中复杂的草地纹理引发了大量的误分类噪声。

## 3. SAM (Segment Anything) 分析:

SAM 在此展示了其对 **显著性物体 (Salient Object)** 的偏好。在 Zero-shot 模式下, 模型优先分割了画面左侧几何特征最规则、边缘最清晰的路桩 (图 (c) 紫色 Mask), 且边缘极其平滑锐利。然而, 对于画面中央较小且边缘不如路桩锐利的“猫”, SAM 在 Top-ranking 的结果中选择了忽略。这说明 SAM 是“强几何弱语义”的, 对于非显著目标, 往往需要人工提示 (Prompt) 才能实现精准捕获。